



Tema 0.

Presentación de la asignatura y ecosistema de herramientas

Cómo funciona el curso y con qué vamos a trabajar

Material teórico | Datos Masivos | Universidad Pontificia Comillas

Dr.^a Blanca Hernández Pardo

Índice de contenidos

CONTEXTO PROFESIONAL	1
QUÉ VAS A APRENDER EN ESTA UNIDAD	1
MAPA CONCEPTUAL DE LA UNIDAD	1
1. MARCO TEÓRICO	2
1.1. Cómo se organiza la asignatura	
1.2. El ecosistema de herramientas: Python y Jupyter Notebook	
1.3. Por qué trabajamos con un entorno virtual	
1.4. Cómo se organizan los materiales de cada unidad	
1.5. Qué verás en cada unidad de la asignatura	
1.6. Qué no se hace en esta unidad	
BIBLIOGRAFÍA	7

Presentación de la asignatura

Bienvenida a Datos Masivos. Esta asignatura no parte de cero: recupera y aplica herramientas de análisis de datos —muchas de ellas ya conocidas de otras asignaturas— a un problema concreto: qué cambia cuando el volumen, la variedad o la velocidad de los datos con los que trabaja un profesional del lenguaje deja de ser manejable «a mano».

A lo largo del curso trabajarás con Python y con Jupyter Notebook para preparar, explorar, organizar, integrar y comunicar datos a una escala mayor de la habitual. Cada unidad parte de un encargo profesional verosímil —una consultoría, un observatorio, una red de traductores— para que el aprendizaje técnico esté siempre conectado con una aplicación real del perfil de Tecnologías del Lenguaje.

Esta primera unidad no analiza ningún dato todavía. Su función es distinta: dejar preparado el terreno. Al terminarla, debes tener tu entorno de trabajo funcionando y entender cómo se organiza el curso, para poder centrarte, desde la unidad siguiente, en el contenido de cada tema sin tener que resolver problemas técnicos de instalación a mitad de una sesión.

Qué vas a aprender en esta unidad

Al terminar esta unidad deberías ser capaz de:

- explicar cómo se organiza la asignatura: sesiones, materiales de cada unidad y evaluación;
- explicar qué es Python, qué es Jupyter Notebook y por qué se usan en el análisis de datos;
- explicar qué es un entorno virtual y por qué esta asignatura trabaja siempre dentro de uno;
- crear, activar, cerrar y volver a activar un entorno virtual por tu cuenta;
- instalar en ese entorno las librerías que necesita cada unidad, sin instalar nada de forma global en tu ordenador.

Mapa conceptual de la unidad

```
Presentación de la asignatura
-> cómo se organizan sesiones y evaluación
-> ecosistema de herramientas: Python y Jupyter
-> por qué un entorno virtual reproducible
-> crear .venv
-> activar .venv
-> instalar dependencias de una unidad
-> trabajar en Jupyter
-> cerrar .venv
-> reutilizar el mismo .venv en la unidad siguiente
```

1. Marco teórico

1.1. Cómo se organiza la asignatura

El curso se estructura en siete unidades, de U0 a U6. Cada unidad se trabaja en dos sesiones: en la primera se presenta el contenido de forma guiada; en la segunda se aplica en una práctica de aula. Antes de empezar cada unidad nueva, hay un breve cuestionario (el «5-minute-paper») que revisa lo aprendido en la unidad anterior: no es un examen, es una comprobación rápida pensada para que puedas resolver dudas antes de avanzar.

La evaluación de la asignatura combina evaluación continua, asistencia y un examen teórico final. El detalle exacto de la ponderación de cada práctica se confirmará durante el curso; lo que sí es estable desde el principio es que cada práctica de aula (salvo la de esta unidad) forma parte de esa evaluación continua, así que conviene tomárselas en serio desde la primera.

1.2. El ecosistema de herramientas: Python y Jupyter Notebook

Python es un lenguaje de programación de propósito general que se ha convertido en el más usado en ciencia de datos y en procesamiento del lenguaje natural, entre otras razones porque cuenta con librerías especializadas muy maduras para trabajar con datos tabulares, texto, bases de datos o visualización.

Jupyter Notebook es un entorno de trabajo que combina, en un mismo documento, código ejecutable, resultados y explicaciones en texto. Un cuaderno de Jupyter (un archivo `.ipynb``) se organiza en celdas: unas contienen código Python que se ejecuta y muestra su resultado justo debajo; otras contienen texto explicativo. Esta combinación es la razón por la que Jupyter se usa tanto en la enseñanza como en el trabajo profesional de análisis de datos: permite documentar, en el mismo lugar, qué se hizo, con qué código y por qué.

A partir de la Unidad 1, la mayoría de las unidades de esta asignatura tienen un cuaderno de Jupyter como material principal.

1.3. Por qué trabajamos con un entorno virtual

Un entorno virtual es una instalación de Python aislada del resto del ordenador, con sus propias librerías. Wilson *et al.* (2017), en una guía de buenas prácticas de computación científica ampliamente adoptada, recomiendan trabajar siempre dentro de un entorno aislado y documentado, en vez de instalar librerías directamente sobre el sistema operativo. Esto evita dos problemas frecuentes: que una librería instalada para una asignatura entre en conflicto con la versión que necesita otro programa del ordenador, y que un cuaderno funcione en un ordenador y falle en otro porque cada uno tiene instaladas versiones distintas de las librerías.

En esta asignatura, ese entorno aislado se llama `.venv``. Se crea una única vez, al principio del curso, y se reutiliza en todas las unidades que trabajen con Python: no hay que crear un entorno nuevo para cada unidad. Lo que sí cambia de una unidad a otra son las librerías instaladas dentro de ese entorno, que se indican en un archivo `requirements_Ux.txt`` propio de cada unidad.

1.4. Cómo se organizan los materiales de cada unidad

Cada unidad de la asignatura, de U1 a U6, sigue la misma estructura de materiales:

- un **manual teórico**, con el contenido explicado y aplicado a un caso profesional;
- un **cuaderno principal**, que se trabaja de forma guiada en la primera sesión de la unidad;
- unas **prácticas**, que se resuelven en la segunda sesión y forman parte de la evaluación continua (salvo en esta unidad);
- un **5-minute-paper**, al principio de la unidad siguiente, que revisa lo aprendido.

Reconocer esta estructura desde el principio te ayudará a saber, en cualquier unidad, dónde encontrar cada cosa.

1.5. Qué verás en cada unidad de la asignatura

De forma orientativa, y sin entrar todavía en el contenido técnico de cada una:

- **U1** caracteriza qué hace que un conjunto de datos sea «masivo» y cómo se sitúa un proyecto dentro de un flujo de trabajo general.
- **U2** prepara, limpia y transforma datos a escala con Python y Pandas.
- **U3** explora y visualiza datos masivos.
- **U4** organiza y cataloga corpus y colecciones documentales extensas.
- **U5** accede e integra datos procedentes de bases de datos y de fuentes externas.
- **U6** automatiza procesos y comunica resultados de forma eficaz.

Cada una de estas unidades desarrollará su propio contenido con detalle cuando llegue el momento; aquí basta con tener una idea general del recorrido completo.

1.6. Qué no se hace en esta unidad

En esta unidad no se analiza ningún dato ni se interpreta ningún resultado: eso empieza en la Unidad 1. Tampoco se profundiza todavía en ningún concepto de datos masivos. El objetivo de U0 es exclusivamente de preparación: entender cómo funciona el curso y dejar tu entorno de trabajo listo para las unidades siguientes.

Bibliografía

Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L. y Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology*, 13(6), e1005510. <https://doi.org/10.1371/journal.pcbi.1005510>