



Tema 1.

Introducción al análisis de datos masivos

Volumen, variedad, velocidad y el flujo de un proyecto de datos

Material teórico | Datos Masivos | Universidad Pontificia Comillas

Dr.^a Blanca Hernández Pardo

Índice de contenidos

ÍNDICE DE CONTENIDOS	1
CONTEXTO PROFESIONAL	1
QUÉ VAS A APRENDER EN ESTA UNIDAD	1
MAPA CONCEPTUAL DE LA UNIDAD	1
1. MARCO TEÓRICO	2
1.1. ¿Qué hace que un dato sea «masivo»?	2
1.2. Más allá de las tres uves: la dimensión crítica	2
1.3. De la analítica de negocio a la analítica aplicada al lenguaje	3
1.4. Análisis convencional frente a análisis escalable	3
1.5. El flujo general de un proyecto de datos	4
1.6. Dónde entra la preparación de datos	5
1.7. Datos masivos en contextos lingüísticos y documentales	5
1.8. Primer contacto práctico: sentir la escala	6
2. APLICACIÓN PRÁCTICA	6
3. QUÉ QUEDA FUERA DE ESTA UNIDAD, Y POR QUÉ	6
BIBLIOGRAFÍA	7

Contexto profesional

Imagina que acabas de incorporarte como analista junior de datos lingüísticos a **Vector Lingüístico**, una consultora ficticia de tecnologías del lenguaje. Tu primer encargo llega de **Ágora FM**, una red pública de emisoras de radio multilingües con más de quince años de emisión continua en varias lenguas cooficiales y de la comunidad migrante.

Ágora FM lleva año tras año acumulando transcripciones de programas, subtítulos para su web y mensajes de la audiencia enviados por redes sociales y formulario. Hasta ahora, su equipo de documentación revisaba ese material «a mano»: hojas de cálculo, carpetas ordenadas por año, búsquedas manuales cuando alguien necesitaba localizar algo. El sistema funcionaba razonablemente bien cuando el archivo era pequeño. Ya no funciona tan bien: los archivos tardan en abrirse, las búsquedas por palabra clave se eternizan, y nadie en la emisora sabe con certeza cuántas horas de transcripción tienen ni en qué estado están.

La dirección de Ágora FM no te pide todavía un análisis lingüístico de sus contenidos. Te pide algo más básico y, a la vez, más importante: un diagnóstico. Quiere saber si lo que tienen es ya un problema de «datos masivos» o si pueden seguir trabajando como hasta ahora. Antes de tocar una sola transcripción, tu trabajo consiste en aprender a hacer esa pregunta correctamente — y en tener un marco conceptual sólido para responderla.

Qué vas a aprender en esta unidad

Al terminar esta unidad deberías ser capaz de:

- explicar qué caracteriza a un dato masivo más allá de «es mucha información»;
- aplicar el marco de las tres uves (volumen, variedad, velocidad) a un caso concreto;
- entender por qué el propio concepto de *big data* ha generado debate crítico, no solo técnico;
- distinguir un análisis de datos convencional de uno pensado para trabajar a escala;
- situar cualquier proyecto de datos dentro de un flujo de trabajo general y reconocer en qué fase se encuentra;
- comprobar de forma práctica, con Python, qué cambia realmente cuando el volumen de datos crece.

Mapa conceptual de la unidad

Caso Ágora FM

- > ¿cuánto volumen, qué variedad, a qué velocidad?
- > ¿esto es ya un problema de datos masivos?
- > análisis convencional vs. análisis escalable
- > flujo general de un proyecto de datos (CRISP-DM)
- > ¿en qué fase estamos?
- > primer contacto práctico: sentir la escala con Python

La idea central de esta unidad es sencilla de enunciar. Sin embargo, aplicarla bien resulta más difícil de lo que parece: no todo problema con muchos datos es un problema de datos masivos, y no toda solución de datos masivos exige empezar por analizar el contenido. Antes de analizar, hay que caracterizar la situación y decidir cómo abordarla. Esa es la fase en la que trabajarás en esta unidad.

1. Marco teórico

1.1. ¿Qué hace que un dato sea «masivo»?

La expresión «datos masivos» (en inglés, *big data*) se ha popularizado hasta el punto de perder precisión. En el uso cotidiano, cualquier archivo grande se llama a veces *big data*, lo cual no ayuda a decidir qué hacer con él. En el ámbito profesional, conviene partir de un criterio más operativo.

La formulación más influyente y más citada es la de Laney (2001), un analista que, trabajando para la consultora META Group, propuso caracterizar los retos de gestión de datos en torno a tres dimensiones, conocidas después como las «tres uves»:

- **Volumen:** la cantidad de datos que hay que almacenar y procesar. Es la dimensión más intuitiva, pero no la única relevante.
- **Variedad:** la diversidad de formatos, estructuras y fuentes de los datos. Un archivo de texto, un audio, una hoja de cálculo y un mensaje de red social no se gestionan igual, aunque hablen del mismo tema.
- **Velocidad:** la rapidez con la que se generan, se necesitan o se actualizan los datos. Un archivo histórico que apenas cambia plantea retos distintos de un flujo que crece cada minuto.

Laney (2001) no hablaba todavía de «datos masivos» en el sentido que hoy le damos, pero su formulación de las tres uves se convirtió en el punto de partida casi obligado de cualquier caracterización posterior del fenómeno. Con el tiempo, otros autores añadieron dimensiones adicionales (veracidad, valor), pero el núcleo de volumen, variedad y velocidad sigue siendo el más citado y el más útil para un primer diagnóstico.

Aplicado al caso de Ágora FM: el **volumen** son los años acumulados de transcripciones y subtítulos; la **variedad** son los distintos formatos (texto transcrito, subtítulos, mensajes de audiencia, metadatos de emisión) y los distintos idiomas; la **velocidad** es la cadencia con la que se genera contenido nuevo cada semana de emisión. Ninguna de las tres dimensiones por separado permite decidir si estamos ante un problema de datos masivos: hay que mirarlas juntas.

1.2. Más allá de las tres uves: la dimensión crítica

Reducir «datos masivos» a un problema exclusivamente técnico de almacenamiento y procesamiento deja fuera una parte importante de la cuestión. Boyd y Crawford (2012) plantean que el *big data* no es solo una cuestión de tamaño: es también un fenómeno cultural y tecnológico que cambia qué preguntas se pueden hacer, quién puede hacerlas y qué se considera una respuesta válida. Su argumento central es que la disponibilidad de grandes volúmenes de datos genera a veces la tentación de creer que «los datos hablan por sí solos», cuando en realidad toda recogida, selección y limpieza de datos implica decisiones humanas que condicionan lo que después se puede afirmar.

Esta advertencia conecta directamente con algo que trabajarás en unidades posteriores: preparar datos no es un trámite neutro (lo verás con más detalle en la Unidad 2), y analizar datos masivos no exime de la responsabilidad de justificar cada decisión metodológica. En el caso de Ágora FM, esto significa que un diagnóstico de «datos masivos» no es solo un informe técnico sobre tamaños de archivo: es también una reflexión sobre qué se puede y qué no se puede concluir a partir de ese archivo, y sobre qué decisiones humanas (qué se transcribió, qué se descartó, qué idiomas se priorizaron) han conformado la colección antes de que llegara a tus manos.

1.3. De la analítica de negocio a la analítica aplicada al lenguaje

El interés por los datos masivos tiene su origen en la analítica de negocio, ajeno en un principio a cualquier aplicación lingüística. Chen *et al.* (2012) describen cómo la disponibilidad creciente de datos empresariales impulsó el paso de una analítica descriptiva tradicional (informes históricos, cuadros de mando) hacia una analítica predictiva y prescriptiva capaz de anticipar comportamientos y apoyar decisiones en tiempo real.

Ese mismo giro —de mirar hacia atrás a intentar anticipar— es el que da sentido a que una asignatura como Datos Masivos exista dentro de un grado en Tecnologías del Lenguaje: un profesional del lenguaje que hoy trabaje con corpus, archivos documentales o interacción con usuarios se va a encontrar antes o después con volúmenes de datos textuales que superan lo que puede revisarse «a mano», igual que le ha ocurrido a Ágora FM con sus transcripciones. Comprender el vocabulario y los marcos conceptuales de la analítica de datos masivos no convierte a un lingüista en ingeniero de datos, pero sí le permite participar en esas conversaciones con criterio propio, en lugar de depender por completo de terceros para decidir qué es viable hacer con un archivo documental extenso.

1.4. Análisis convencional frente a análisis escalable

Un análisis de datos «convencional» suele partir de un conjunto de datos que cabe cómodamente en la memoria de un ordenador, que se puede revisar visualmente sin demasiado esfuerzo y que no cambia mientras se trabaja con él. Un análisis pensado para trabajar **a escala** anticipa que alguna de esas tres condiciones puede fallar: el archivo puede ser demasiado grande para abrirlo entero en una hoja de cálculo, puede llegar en fragmentos sucesivos en vez de completo desde el principio, o puede tener una estructura tan variable que no exista una única forma de leerlo.

La diferencia no es solo de tamaño, sino de actitud metodológica. Trabajar a escala implica, entre otras cosas:

- preferir herramientas que no requieran cargar todo el archivo en memoria de golpe cuando el volumen lo desaconseje;
- documentar y automatizar los pasos, porque no va a ser viable revisar cada registro uno a uno;
- aceptar que la inspección será necesariamente parcial (por muestreo, por agregados) en vez de exhaustiva;
- anticipar que los datos pueden seguir creciendo mientras se trabaja con ellos.

En el caso de Ágora FM, la pregunta que debes responder no es cuántos años de transcripciones tienen: es qué de todo lo anterior deja de ser viable con el volumen, la variedad y la velocidad que tiene

su archivo. Esa es la pregunta que separa un análisis convencional de uno pensado para trabajar a escala.

1.5. El flujo general de un proyecto de datos

Para no perderse dentro de un proyecto de datos, conviene apoyarse en un modelo de flujo de trabajo. Uno de los más usados y mejor documentados en la práctica profesional es CRISP-DM (*Cross-Industry Standard Process for Data Mining*), formulado por Chapman *et al.* (2000). El modelo describe seis fases, no necesariamente lineales:

1. **Comprensión del negocio o del encargo:** entender qué problema se quiere resolver y qué criterio definirá el éxito, antes de mirar ningún dato.
2. **Comprensión de los datos:** explorar de forma inicial qué datos existen, de dónde vienen y qué calidad tienen.
3. **Preparación de los datos:** limpiar, transformar y estructurar los datos para que puedan analizarse (esta es, en gran medida, la fase que trabajarás en la Unidad 2).
4. **Modelado:** aplicar técnicas de análisis, estadística o aprendizaje automático sobre los datos ya preparados.
5. **Evaluación:** comprobar si los resultados responden realmente al problema planteado en la primera fase.
6. **Despliegue:** poner los resultados a disposición de quien los necesita, de forma que puedan usarse.




Figura 1. Fases del proceso CRISP-DM (elaboración propia).

Este modelo es útil por dos motivos. Primero, porque deja claro que «analizar datos» no es la primera tarea de un proyecto, sino una de las últimas: antes hay que entender el encargo y entender los datos disponibles. Segundo, porque permite situar cualquier tarea concreta —incluida esta unidad— dentro de un mapa más amplio. El encargo de Ágora FM corresponde, en términos de CRISP-DM, a las dos primeras fases: comprensión del encargo (¿qué necesita realmente la emisora?) y comprensión de los datos (¿qué tienen, en qué volumen, con qué variedad, a qué velocidad?). Todavía no toca preparar, modelar ni desplegar nada.

1.6. Dónde entra la preparación de datos

Conviene anticipar, aunque sea brevemente, por qué la preparación de datos (fase 3 de CRISP-DM) recibe tanta atención en esta asignatura. Kandel *et al.* (2012), a partir de entrevistas a analistas en entornos empresariales reales, documentan que gran parte del tiempo real de un proyecto de datos se dedica a localizar, limpiar y estructurar la información, mucho antes de que empiece cualquier análisis en el sentido más visible del término. Esta observación se cumple con más fuerza cuanto mayor es el volumen y la variedad de los datos: un archivo pequeño y homogéneo puede prepararse en minutos; un archivo como el de Ágora FM, acumulado durante quince años en varios idiomas y formatos, puede requerir semanas de trabajo de preparación antes de que tenga sentido analizar su contenido.

Esta es una de las razones por las que un diagnóstico de datos masivos no puede limitarse a decir «sí, esto es mucho volumen»: tiene que anticipar en qué medida esa característica va a condicionar el trabajo de las fases siguientes.

1.7. Datos masivos en contextos lingüísticos y documentales

Para un profesional de Tecnologías del Lenguaje, los datos masivos suelen presentarse como colecciones de texto —transcripciones, corpus, subtítulos, mensajes de usuarios, documentación institucional— y no como tablas numéricas. Esto no cambia el marco conceptual de las tres uves ni el flujo CRISP-DM, pero sí añade matices propios:

- la **variedad** suele incluir variedad lingüística (idiomas, variantes, registros), no solo variedad de formato de archivo;
- la **velocidad** puede estar marcada por la cadencia de producción de contenido (emisiones diarias, publicaciones en redes) más que por sensores o transacciones;
- el **volumen** de un archivo textual se mide tanto en megabytes como en número de documentos, de palabras o de horas de audio transcrito.

Estas unidades de la asignatura (de la Unidad 2 a la Unidad 6) trabajarán, en este orden, la preparación de datos a escala, su exploración y visualización, la organización de colecciones documentales extensas, el acceso a fuentes de datos externas y, por último, la automatización y comunicación de resultados. Todo ese recorrido presupone el diagnóstico que aprenderás a hacer en esta unidad: sin caracterizar antes el problema, no tiene sentido elegir una herramienta ni una técnica.

1.8. Primer contacto práctico: sentir la escala

La teoría explica qué cambia cuando el volumen crece, pero conviene comprobarlo de forma directa. En el cuaderno de esta unidad trabajarás con dos versiones de un mismo catálogo sintético del archivo de Ágora FM: una pequeña, fácil de inspeccionar de un vistazo, y otra mucho más grande. Usando herramientas que ya conoces de Pandas, compararás cuánto ocupa cada una en memoria, cuánto tarda en ejecutarse la misma operación sobre una y otra, y qué deja de ser cómodo hacer «a simple vista» cuando el número de filas crece. No se trata de aprender ninguna técnica nueva de programación, sino de usar lo que ya sabes para observar, con datos delante, la diferencia entre trabajar con un archivo pequeño y trabajar con uno grande.

2. Aplicación práctica

En el cuaderno principal y en las prácticas de esta unidad seguirás este recorrido:

1. revisar los datos sintéticos disponibles sobre el archivo de Ágora FM;
2. caracterizar el caso con el marco de las tres uves;
3. situar el encargo dentro del flujo CRISP-DM y decidir en qué fase se encuentra;
4. comprobar en Python, con los catálogos pequeño y grande, qué cambia al aumentar el volumen;
5. redactar un diagnóstico breve, apoyado en los criterios anteriores, no en impresiones subjetivas.

El resultado no será un análisis del contenido de las transcripciones de Ágora FM. Será un diagnóstico metodológico: la base sobre la que, en las unidades siguientes, se podrá decidir cómo preparar, explorar y organizar ese archivo.

3. Qué queda fuera de esta unidad, y por qué

Por qué no se analiza el contenido de ninguna transcripción ni mensaje de audiencia. El encargo de Ágora FM, en esta unidad, es un diagnóstico metodológico —¿es esto ya un problema de datos masivos?—, no un análisis lingüístico del contenido. Analizar lo que dicen las transcripciones pertenece a una fase posterior del proyecto (preparación, exploración), que trabajarás en las unidades siguientes, no a la fase de comprensión inicial en la que te sitúa CRISP-DM aquí. No es que el contenido no importe: es que todavía no ha llegado su turno.

Por qué no se calculan estadísticas sobre datos reales de ninguna emisora. Los catálogos que usas en esta unidad son sintéticos, contruidos para la asignatura y declarados como tales en la ficha de la unidad. No representan cifras reales de Ágora FM ni de ninguna emisora existente, así que cualquier estadística que calcules sobre ellos es válida como ejercicio metodológico, pero no debe presentarse ni interpretarse como un dato real sobre una organización real.

Por qué se insiste tanto en no confundir «tener muchos datos» con «tener un problema de datos masivos». Esto no es una restricción añadida: es el propio contenido central de la unidad. Las tres uves solo tienen sentido si se miran juntas. Un archivo puede tener mucho volumen y, aun así, no plantear ningún reto especial si su variedad y su velocidad son bajas. Adelantar una conclusión mirando solo el volumen es precisamente el error metodológico que esta unidad quiere enseñarte a evitar.

Por qué no se inventan cifras que no estén en los materiales de la unidad. Esta norma se aplica a toda la asignatura, no solo a esta unidad: cualquier cifra, dato o conclusión que uses debe poder señalarse en un archivo o resultado concreto. Es la misma exigencia que se te pedirá en un encargo profesional real, donde presentar como dato algo que no se puede verificar tiene consecuencias serias para quien firma el informe.

Bibliografía

Boyd, D., y Crawford, K. (2012). Critical questions for big data: Provocations for a cultural, technological, and scholarly phenomenon. *Information, Communication & Society*, 15(5), 662-679. <https://doi.org/10.1080/1369118X.2012.678878>

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Chen, H., Chiang, R. H. L. y Storey, V. C. (2012). Business intelligence and analytics: From big data to big impact. *MIS Quarterly*, 36(4), 1165-1188. <https://doi.org/10.2307/41703503>

Kandel, S., Paepcke, A., Hellerstein, J. M. y Heer, J. (2012). Enterprise data analysis and visualization: An interview study. *IEEE Transactions on Visualization and Computer Graphics*, 18(12), 2917-2926. <https://doi.org/10.1109/TVCG.2012.219>

Laney, D. (2001). *3D data management: Controlling data volume, velocity, and variety* (META Group Research Note, 6). META Group.

McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56-61. <https://doi.org/10.25080/Majora-92bf1922-00a>

The pandas development team. (2020). *pandas-dev/pandas: Pandas* [Computer software]. Zenodo. <https://doi.org/10.5281/zenodo.3509134>