



Tema 1.

Introducción al análisis de datos masivos

Prácticas: diagnóstico del Buzón de Voces

Prácticas | Datos Masivos | Universidad Pontificia Comillas

Dr.^a Blanca Hernández Pardo

U1. Prácticas del alumno

Encargo

Vector Lingüístico recibe una segunda petición de Ágora FM. Esta vez, la dirección se centra en el «Buzón de Voces»: los mensajes que la audiencia envía por redes sociales y formulario web, que en los últimos años han crecido mucho más deprisa que el resto del archivo y preocupan especialmente al equipo de comunicación.

El contexto profesional es el mismo que en el cuaderno principal: trabajas como analista junior de datos lingüísticos en Vector Lingüístico. Tu tarea es repetir el diagnóstico de las tres uves sobre el Buzón de Voces, comparando un catálogo de 2021 con uno actual de 2025-2026, y entregar una conclusión razonada.

Material de entrada

- materiales/U1_practica_buzon_2021.csv.
- materiales/U1_practica_buzon_2026.csv.

Tareas

1. Carga los dos catálogos con Pandas.
2. Compara su volumen: número de filas, columnas y memoria ocupada (recuerda usar `memory_usage(deep=True)`).
3. Cronometra sobre ambos catálogos la misma operación no vectorizada usada en el cuaderno de clase (contar documentos con `num_palabras` superior a un umbral que tú elijas y justifiques).
4. Compara su variedad: número de emisoras e idiomas distintos en cada catálogo.
5. Añade al final del cuaderno una celda de Markdown con tu diagnóstico: ¿es ya el Buzón de Voces un problema de datos masivos? Justifica con las cifras obtenidas, no con impresiones.

Entregables

- Cuaderno de Python (.ipynb) con el código y los resultados de la comparación.
- En el propio cuaderno, la celda final de Markdown con el diagnóstico justificado.

Límites de la práctica

- No calcules ni menciones cifras reales de ninguna emisora de radio existente: los catálogos son sintéticos.
- No uses técnicas distintas de las trabajadas en el cuaderno de clase de esta unidad.
- No uses rutas absolutas sin explicar cómo debe adaptarlas otra persona.

Criterios de revisión

Criterio	Evidencia esperada
Volumen	Calcula y compara correctamente filas, columnas y memoria de ambos catálogos.

Velocidad	Cronometra la misma operación no vectorizada en los dos catálogos y compara los tiempos.
Variedad	Compara correctamente el número de categorías distintas entre catálogos.
Diagnóstico justificado	La conclusión se apoya en las cifras obtenidas, no en impresiones subjetivas.
Límites respetados	No analiza contenido ni introduce datos reales de emisoras existentes.

Relación con el cuaderno de clase

Esta práctica se resuelve con el mismo código, el mismo flujo y las mismas operaciones enseñadas en el cuaderno principal de trabajo del tema 1: cambia el catálogo concreto y el umbral de palabras que elijas para contar documentos largos, pero no la técnica.