

Tema 2.

Preparación, limpieza y transformación de datos a escala

Prácticas: preparación autónoma de una colección textual

Prácticas | Datos Masivos | Universidad Pontificia Comillas

Dr.^a Blanca Hernández Pardo

U2. Prácticas del alumno

Encargo

LexiData Observatorio recibe una segunda petición del Servicio de Observación Documental y Comunicación Pública. Después del trabajo guiado en el aula, el cliente necesita que prepares de forma autónoma una versión revisable del archivo `U2_tweets_brutos.json`.

El contexto profesional es el mismo que en la unidad: trabajas como lingüista computacional junior y tu responsabilidad es preparar datos textuales para una fase posterior, sin interpretar todavía el contenido de los mensajes.

Material de entrada

- `materiales/U2_tweets_brutos.json`.

Tareas

1. Importa el JSON con Python.
2. Convierte los registros en un *dataframe*.
3. Selecciona columnas útiles para un análisis documental inicial: identificador, fecha, texto, idioma, usuario, ubicación y fuente.
4. Añade al menos tres columnas derivadas descriptivas. Puedes usar longitud del texto, número de menciones, número de URL, número de hashtags o marca de retuit.
5. Revisa valores ausentes y duplicados.
6. Exporta el resultado como `U2_practica_tweets_preparados.csv`.
7. Añade al final del cuaderno una celda de Markdown donde justifiques, con tus propias palabras, las principales decisiones tomadas.

Entregables

- Cuaderno de Python (`.ipynb`) usado para preparar los datos.
- CSV final.
- En el cuaderno de Python, una última celda de Markdown donde justifiques, con tus propias palabras, las principales decisiones que has tomado y por qué. Extensión orientativa: 200-250 palabras.

Límites de la práctica

- No modifiques el archivo bruto.
- No uses rutas absolutas sin explicar cómo debe adaptarlas otra persona.

Criterios de revisión

Criterio	Evidencia esperada
Importación y reproducibilidad	Usa una ruta clara, modificable y documentada, y carga correctamente el JSON.
Estructuración tabular	Cada fila representa un mensaje y las columnas son interpretables.
Selección de variables	Conserva campos relevantes para el encargo.
Limpieza e inconsistencias	Revisa duplicados, ausentes y campos técnicos.
Transformaciones derivadas	Añade variables descriptivas sin interpretación indebida.
Exportación y documentación	Entrega CSV y justificación final clara en el cuaderno.

Relación con el cuaderno de clase

La práctica está diseñada para resolverse con el mismo código y el mismo flujo enseñados en el cuaderno principal de trabajo del tema 2, adaptando únicamente la ruta del archivo de entrada, el nombre del CSV de salida y la justificación final solicitada. No se exige ninguna técnica nueva.