



Tema 4.

Corpus y colecciones documentales extensas

Prácticas: catálogo de los recortes de prensa

Prácticas | Datos Masivos | Universidad Pontificia Comillas

Dr.^a Blanca Hernández Pardo

U4. Prácticas del alumno

Encargo

Corpus & Contexto recibe una segunda petición de la Fundación Orellana. Esta vez, el encargo se centra específicamente en los recortes de prensa: una subcolección más numerosa que las cartas y los manuscritos, y que la Fundación quiere catalogar por separado porque procede de dos fondos distintos, prensa nacional y prensa regional.

El contexto profesional es el mismo que en el cuaderno principal: trabajas como analista junior de datos documentales en Corpus & Contexto. Tu tarea es repetir el catálogo del cuaderno principal de trabajo del tema 4 sobre esta nueva colección de recortes de prensa.

Material de entrada

- materiales/coleccion_orellana_recortes/ (dos subcarpetas: prensa_nacional/ y prensa_regional/).

Tareas

1. Recorre la carpeta materiales/coleccion_orellana_recortes/ con pathlib y localiza todos los archivos .txt.
2. Extrae, para cada documento, su nombre, su subcarpeta, su tamaño y su recuento aproximado de palabras.
3. Construye un catálogo con Pandas (un registro por documento).
4. Calcula un resumen agregado por subcarpeta (número de documentos y palabras totales).
5. Exporta el catálogo completo como U4_practica_catalogo_recortes.csv y el resumen como U4_practica_catalogo_recortes_resumen.csv.
6. Añade al final del cuaderno una celda de Markdown donde indiques cuál de los dos fondos (nacional o regional) tiene más documentos y cuál tiene más palabras en total, y si ambas cosas coinciden.

Entregables

- Cuaderno de Python (.ipynb) con el código y los resultados.
- Los dos CSV exportados.
- En el propio cuaderno, la celda final de Markdown con la comparación solicitada.

Límites de la práctica

- No inventes ningún dato que no conste en los archivos de la colección.
- No uses técnicas distintas de las trabajadas en el cuaderno de clase de esta unidad.
- No uses rutas absolutas sin explicar cómo debe adaptarlas otra persona.

Criterios de revisión

Criterio	Evidencia esperada
Recorrido de carpetas	Localiza correctamente todos los archivos .txt de las dos subcarpetas con pathlib.

Extracción de metadatos	Obtiene nombre, subcarpeta, tamaño y recuento de palabras de cada documento.
Catálogo con Pandas	Construye correctamente el dataframe con un registro por documento.
Agregados y exportación	Calcula el resumen por subcarpeta y exporta ambos CSV correctamente.
Comparación final	La celda final compara documentos y palabras entre los dos fondos con las cifras obtenidas.

Relación con el cuaderno de clase

Esta práctica se resuelve con el mismo código, el mismo flujo y las mismas operaciones enseñadas en el cuaderno principal de trabajo del tema 4: cambia la colección concreta (recortes de prensa en vez de cartas, manuscritos y prensa), pero no la técnica.