



Tema 5.

Almacenamiento y acceso a datos a gran escala

Prácticas: cobertura terminológica por proyecto

Prácticas | Datos Masivos | Universidad Pontificia Comillas

Dr.^a Blanca Hernández Pardo

U5. Prácticas del alumno

Encargo

La Red Iberia de Traducción Jurídica pide a Términos & Trama una segunda comprobación: esta vez sobre una muestra distinta de su base de datos de términos, y con una pregunta adicional: ¿qué proyecto de traducción tiene, en proporción, más términos todavía sin equivalente externo?

El contexto profesional es el mismo que en el cuaderno principal: trabajas como analista junior de datos terminológicos en Términos & Trama. Tu tarea es repetir el cruce del cuaderno principal de trabajo del tema 5 sobre esta nueva base de datos y añadir un desglose por proyecto.

Material de entrada

- materiales/terminos_internos_practica.db (tabla terminos_internos).
- materiales/glosario_externo_practica.csv.

Tareas

1. Conecta con la base de datos y consulta la tabla terminos_internos con SQL desde Pandas.
2. Carga el glosario externo con Pandas.
3. Normaliza el campo de término en ambas fuentes y cruza los datos, igual que en el cuaderno de clase.
4. Calcula cuántos registros tienen equivalente externo y cuántos no.
5. Calcula, para cada proyecto, la proporción de sus términos que tiene equivalente externo (puedes usar groupby, ya trabajado en U4).
6. Exporta el resultado como U5_practica_informe_cobertura.csv y como una tabla nueva en la base de datos.
7. Añade al final del cuaderno una celda de Markdown indicando qué proyecto tiene menor proporción de cobertura y qué le recomendarías a la Red Iberia sobre ese proyecto en particular.

Entregables

- Cuaderno de Python (.ipynb) con el código y los resultados.
- El CSV exportado.
- En el propio cuaderno, la celda final de Markdown con la recomendación.

Límites de la práctica

- No evalúes la calidad de ninguna traducción.
- No inventes términos, equivalencias o proyectos que no consten en los datos proporcionados.
- No modifiques la tabla original terminos_internos: cualquier resultado nuevo va en una tabla aparte.
- No uses técnicas distintas de las trabajadas en el cuaderno de clase de esta unidad y en U4 (groupby).

Criterios de revisión

Criterio	Evidencia esperada
----------	--------------------

Consulta SQL	Consulta correctamente la base de datos con <code>read_sql_query()</code> .
Fuente externa	Carga correctamente el glosario externo con <code>read_csv()</code> .
Cruce normalizado	Normaliza el término en ambas fuentes antes de cruzar.
Desglose por proyecto	Calcula correctamente la proporción de cobertura por proyecto.
Exportación y recomendación	Exporta correctamente y la recomendación final se apoya en las cifras obtenidas.

Relación con el cuaderno de clase

Esta práctica se resuelve con el mismo código, el mismo flujo y las mismas operaciones enseñadas en el cuaderno principal de trabajo del tema 5, añadiendo un `groupby` ya trabajado en el tema 4 para el desglose por proyecto: cambia la base de datos concreta, pero no la técnica.