



Tema 6.

Automatización y comunicación de resultados a gran escala

De la tarea repetida a mano al informe automático

Material teórico | Datos Masivos | Universidad Pontificia Comillas

Dr.^a Blanca Hernández Pardo

Índice de contenidos

ÍNDICE DE CONTENIDOS	1
CONTEXTO PROFESIONAL	1
QUÉ VAS A APRENDER EN ESTA UNIDAD	1
MAPA CONCEPTUAL DE LA UNIDAD	1
1. MARCO TEÓRICO	2
1.1. Por qué automatizar	2
1.2. De la celda de cuaderno a la función reutilizable	2
1.3. Buenas prácticas de automatización y reproducibilidad	3
1.4. Exportar un informe a Excel con varias hojas	3
1.5. Comunicar resultados a una audiencia no técnica	3
1.6. Un apunte sobre herramientas de paneles	4
2. APLICACIÓN PRÁCTICA	4
2.1. Aplicación al caso del Observatorio de Neologismos	4
2.2. Bloque final opcional: la misma función sobre datos reales de Wikipedia	5
3. QUÉ QUEDA FUERA DE ESTA UNIDAD, Y POR QUÉ	5
BIBLIOGRAFÍA	6

Contexto profesional

Imagina que acabas de incorporarte como analista junior de datos lingüísticos a **Bitácora de Datos**, una consultora ficticia de análisis de datos lingüísticos. Tu cliente es el **Observatorio de Neologismos**, una entidad ficticia que rastrea cada mes la aparición de palabras nuevas en medios de comunicación: anglicismos, términos tecnológicos, expresiones surgidas en redes sociales.

Cada mes, alguien del Observatorio recibe un archivo con los neologismos detectados y sus frecuencias, y construye a mano, copiando y pegando en una hoja de cálculo, un informe con los términos más frecuentes y un gráfico resumen para el boletín mensual. Ese proceso funcionaba cuando el Observatorio empezó. Ahora reciben datos de más fuentes cada mes y el informe manual empieza a llegar tarde, además de ser propenso a errores de copiado. Tu encargo es automatizar ese proceso: que el mismo informe se genere en minutos, con el mismo formato, cada vez que llegue un archivo nuevo.

Qué vas a aprender en esta unidad

Al terminar esta unidad deberías ser capaz de:

- explicar qué gana un flujo de trabajo cuando se automatiza frente a repetirlo manualmente;
- escribir una función en Python que procese un archivo de datos y genere un informe;
- aplicar la misma función a distintos archivos de entrada sin modificar el código;
- exportar resultados a un informe en Excel con varias hojas;
- comunicar un resultado con un gráfico resumen pensado para una audiencia no técnica.

Mapa conceptual de la unidad

```
Archivo mensual de neologismos
-> función de procesamiento (la misma cada mes)
-> resumen por categoría
-> top de términos más frecuentes
-> informe en Excel (varias hojas)
-> gráfico resumen
-> boletín del Observatorio
```

Esta unidad cierra el recorrido de la asignatura: en la Unidad 2 aprendiste a preparar datos, en la Unidad 3 a explorarlos y visualizarlos, en la Unidad 4 a catalogar colecciones extensas, en la Unidad 5 a acceder a fuentes internas y externas. En esta unidad el objetivo es distinto: que todo ese trabajo, una vez resuelto correctamente, no haya que rehacerlo desde cero cada vez que lleguen datos nuevos.

1. Marco teórico

1.1. Por qué automatizar

Kandel *et al.* (2012) documentan que buena parte del tiempo de un proyecto de datos se dedica a tareas de preparación y estructuración, no al análisis en sí. Cuando esas tareas se repiten periódicamente sobre datos con la misma estructura —un informe mensual, un resumen semanal—, repetir manualmente cada vez el mismo proceso no solo consume tiempo: introduce el riesgo de que una persona distinta, o la misma persona en un mes distinto, lo haga de forma ligeramente diferente, sin darse cuenta.

Automatizar no significa necesariamente programas complejos ni infraestructuras costosas. En muchos casos, como en el del Observatorio de Neologismos, automatizar significa simplemente escribir una vez, de forma cuidadosa, el código que resuelve la tarea, y organizarlo de manera que se pueda volver a ejecutar sobre datos nuevos sin tocar una sola línea.

1.2. De la celda de cuaderno a la función reutilizable

Hasta ahora, los cuadernos de esta asignatura resolvían un encargo concreto sobre un archivo concreto. Para que ese mismo trabajo se pueda repetir sobre archivos distintos sin copiar y pegar celdas, conviene organizarlo como una función: un bloque de código con un nombre, que recibe una entrada (por ejemplo, la ruta de un archivo mensual) y devuelve o guarda un resultado.

La diferencia práctica es importante. Un cuaderno que procesa `neologismos_enero.csv` tiene ese nombre de archivo escrito en alguna celda. Una función `generar_informe_mensual(ruta_archivo)` puede llamarse una vez con `"neologismos_enero.csv"` y otra con `"neologismos_febrero.csv"`, ejecutando exactamente el mismo código las dos veces, sin haber tenido que modificar ni revisar nada entre una llamada y otra.




Figura 1. La misma función aplicada a archivos mensuales distintos (elaboración propia).

1.3. Buenas prácticas de automatización y reproducibilidad

Wilson *et al.* (2017), ya citados en la Unidad 4 a propósito de la organización de archivos y carpetas, también recomiendan explícitamente automatizar mediante scripts cualquier tarea que vaya a repetirse, en vez de fiarse de pasos manuales que alguien pueda olvidar u omitir. Un cuaderno interactivo es una herramienta excelente para explorar y desarrollar una solución paso a paso, pero cuando esa solución ya está resuelta y hay que repetirla de forma periódica, conviene convertirla en un script que se pueda ejecutar de principio a fin sin intervención manual.

Python permite convertir un cuaderno Jupyter ya terminado en un script ejecutable con la orden `jupyter nbconvert --to script nombre_del_cuaderno.ipynb`, que genera un archivo `.py` con todo el código de las celdas del cuaderno, en el mismo orden. Ese script puede ejecutarse directamente desde la terminal, o programarse para que se ejecute automáticamente a intervalos regulares, sin necesidad de abrir Jupyter cada vez.

1.4. Exportar un informe a Excel con varias hojas

Un informe rara vez cabe en una sola tabla. El Observatorio de Neologismos necesita, como mínimo, un resumen por categoría y un listado de los términos más frecuentes: dos vistas distintas de los mismos datos. Pandas permite escribir varias tablas en el mismo archivo Excel, cada una en su propia hoja, usando un objeto `ExcelWriter`: se abre el archivo una vez y se van añadiendo tablas indicando el nombre de la hoja en cada caso.

Este informe de varias hojas es, en la práctica, el mismo tipo de exportación que ya se trabajó en la Unidad 2 (`to_csv`) y en la Unidad 5 (`to_sql`), aplicada ahora a un formato pensado para que una persona no técnica lo abra directamente en una hoja de cálculo y lo revise sin necesidad de escribir ni una línea de código.

1.5. Comunicar resultados a una audiencia no técnica

Automatizar el cálculo es solo la mitad del encargo: el resultado tiene que poder entenderse. Nussbaumer Knaflic (2015) insiste en que comunicar datos de forma eficaz exige pensar primero en quién va a leer el resultado y qué necesita entender, antes de decidir qué gráfico o qué tabla usar. Un boletín mensual dirigido al público general del Observatorio no necesita una tabla completa con centenares de neologismos: necesita una idea clara y rápida de cuáles son los términos del mes.

Una técnica concreta que propone la misma autora para llegar a esa claridad es resumir, antes de construir ningún gráfico, el mensaje central en una sola frase: no «los datos de neologismos de este mes», sino algo del tipo «este mes, los anglicismos han dominado claramente el boletín, con casi el doble de menciones que la segunda categoría». Esa frase —lo que Nussbaumer Knaflic (2015) llama la idea central del informe— es la que debe guiar qué tabla y qué gráfico se construyen después, y no al revés.

Aquí conviene recuperar lo aprendido en la Unidad 3: un gráfico de barras simple, con los términos más frecuentes ordenados de mayor a menor, comunica esa idea mucho mejor que una tabla extensa. La diferencia respecto a la Unidad 3 no está en la técnica —se sigue usando Matplotlib—, sino en el

propósito: en la Unidad 3 el gráfico servía para explorar datos; aquí sirve para comunicar una conclusión ya obtenida a alguien que no va a leer el código ni el proceso, solo el resultado.

Nussbaumer Knaflic (2015) explica además que el ojo humano detecta antes que nada ciertos atributos visuales —el color, el tamaño, la posición— antes incluso de leer ninguna etiqueta; a esto lo llama atributos preatentivos. Aplicado al gráfico de barras de esta unidad, esto tiene una consecuencia práctica sencilla: si el boletín quiere destacar el término más frecuente del mes, basta con pintar esa barra de un color distinto al resto, en vez de dejar todas las barras del mismo color y confiar en que quien lea el gráfico haga ese trabajo de comparación por su cuenta.

Además, un gráfico de barras solo comunica una comparación honesta si el eje de valores empieza en cero: como la altura de cada barra es lo que el ojo interpreta como la cantidad que representa, recortar el eje para empezar en un valor distinto de cero exagera visualmente las diferencias entre términos, aunque los números de la tabla sean correctos (Wilke, 2019). Esta es una de las pocas reglas de diseño de gráficos que no admite excepciones cuando se trabaja con barras, y conviene revisarla en el propio gráfico antes de darlo por bueno.

Para acompañar el gráfico con texto, Dougherty e Ilyankou (2021) proponen una estructura sencilla de tres pasos: primero enunciar el hallazgo (qué ha pasado), después mostrar la evidencia visual que lo respalda (el gráfico), y por último explicar por qué importa (qué debería hacer o saber quien lee el boletín a partir de ese dato). Aplicado al Observatorio de Neologismos, esto significa no limitarse a poner un gráfico de barras sin contexto, sino acompañarlo de una frase que diga qué categoría ha destacado este mes y por qué eso es relevante para quien sigue el boletín.

1.6. Un apunte sobre herramientas de paneles

Existen herramientas específicas para construir paneles de control interactivos a partir de datos, como Power BI, que permiten conectar directamente con los resultados generados en Python y presentarlos de forma visual e interactiva para quien los consulte. Esta unidad no exige el uso de Power BI ni de ninguna herramienta equivalente: la disponibilidad de ese tipo de software depende del equipo de cada aula. Lo importante, a efectos de esta unidad, es que un informe bien automatizado y bien comunicado en Python —como el que vas a construir— es exactamente el tipo de resultado que después podría conectarse a una herramienta de paneles, si se dispusiera de ella: la lógica de fondo (automatizar el cálculo, estructurar el resultado, pensar en la audiencia) no cambia según la herramienta final de presentación.

2. Aplicación práctica

2.1. Aplicación al caso del Observatorio de Neologismos

En el cuaderno de clase seguirás este recorrido:

1. escribir una función `generar_informe_mensual()` que reciba la ruta de un archivo mensual;
2. dentro de la función, calcular el resumen por categoría y el top de términos más frecuentes;
3. exportar ambas tablas a un informe Excel con dos hojas;
4. generar un gráfico de barras con los términos más frecuentes del mes;

5. aplicar la misma función, sin modificarla, a los archivos de enero y de febrero.

El resultado no analizará por qué un término se ha vuelto frecuente ni qué significa lingüísticamente. Se limita a automatizar el procesamiento de una tarea que el Observatorio ya sabía hacer, para que pueda repetirse cada mes sin esfuerzo adicional.

2.2. Bloque final opcional: la misma función sobre datos reales de Wikipedia

Al final del cuaderno de clase hay un bloque opcional, que no se evalúa, en el que `generar_informe_mensual()` se aplica, sin modificar ni una línea, a un archivo real: términos tomados de cuatro categorías reales de Wikipedia en español (Anglicismos, Terminología informática, Redes sociales y Neologismos), con su frecuencia real de consulta durante un mes real (número de visitas a cada página, según la API pública de estadísticas de Wikimedia). El archivo ya está preparado en los materiales de la unidad; no se descarga durante la sesión.

El resultado real no repite el patrón de los datos sintéticos de enero y febrero (donde «anglicismo» siempre lideraba): con términos reales, el orden depende de qué artículos concretos hay en cada categoría de Wikipedia y de cuánto se han consultado ese mes, no de un patrón fijado de antemano. Esto es, en sí mismo, la lección del bloque: la función automatizada no sabe ni le importa si los datos son sintéticos o reales, y por eso conviene distinguir con cuidado, al leer cualquier informe automatizado, qué hay detrás de las cifras que produce.

3. Qué queda fuera de esta unidad, y por qué

Por qué no se analiza el origen ni el significado lingüístico de ningún neologismo. A diferencia de otras restricciones de esta asignatura, esta no remite a Programación orientada a PLN: la etimología y la semántica léxica de los neologismos no se cubren en ninguna asignatura de este recorrido tal y como está diseñado ahora mismo. La razón de fondo es distinta: el objetivo de esta unidad es que aprendas a automatizar el procesamiento de un informe mensual y a comunicarlo con claridad, no a interpretar por qué un término concreto se ha vuelto frecuente. Son dos preguntas legítimas, pero solo la primera pertenece a esta unidad.

Por qué no se inventan términos ni frecuencias que no consten en los archivos proporcionados. Esta norma se aplica a toda la asignatura: cualquier término o frecuencia que uses debe poder rastrearse hasta el archivo de entrada correspondiente. Un informe automatizado que reporta cifras inventadas es peor que no tener informe: transmite una falsa sensación de rigor.

Por qué no se exige el uso de Power BI ni de ninguna herramienta de paneles no disponible en el aula. Ya se explica en el apartado sobre herramientas de paneles de este mismo manual: la disponibilidad de ese tipo de software depende del equipo de cada aula, y la lógica de fondo que aprendes aquí —automatizar el cálculo, estructurar el resultado, pensar en la audiencia— no cambia según cuál sea la herramienta final de presentación. Un informe bien automatizado en Python es exactamente el tipo de resultado que después podría conectarse a Power BI o a cualquier herramienta equivalente, si llegaras a tener acceso a ella.

Bibliografía

Dougherty, J. y Ilyankou, I. (2021). *Hands-on data visualization: Interactive storytelling from spreadsheets to code*. O'Reilly Media.

Kandel, S., Paepcke, A., Hellerstein, J. M. y Heer, J. (2012). Enterprise data analysis and visualization: An interview study. *IEEE Transactions on Visualization and Computer Graphics*, 18(12), 2917-2926. <https://doi.org/10.1109/TVCG.2012.219>

McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56-61. <https://doi.org/10.25080/Majora-92bf1922-00a>

Nussbaumer Knaflic, C. (2015). *Storytelling with data: A data visualization guide for business professionals*. Wiley.

The pandas development team. (2020). *pandas-dev/pandas: Pandas* [Computer software]. Zenodo. <https://doi.org/10.5281/zenodo.3509134>

Wikimedia Foundation. (s. f.). Wikimedia Pageviews Analysis [Conjunto de datos]. Recuperado el 28 de julio de 2026 de https://wikimedia.org/api/rest_v1/

Wikipedia. (s. f.). Categoría:Anglicismos; Categoría:Neologismos; Categoría:Redes sociales; Categoría:Terminología informática. Recuperado el 28 de julio de 2026 de <https://es.wikipedia.org/>

Wilke, C. O. (2019). *Fundamentals of data visualization: A primer on making informative and compelling figures*. O'Reilly Media.

Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L. y Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology*, 13(6), e1005510. <https://doi.org/10.1371/journal.pcbi.1005510>